

# 吴亚伦

✉ aaronwww@outlook.com  
(+86) 189-4058-1177 (+65) 9812-5849  
📍 新加坡国立大学, 新加坡

## 🎓 教育背景

北京航空航天大学 (BUAA)

工学学士, 网络空间安全专业

新加坡国立大学 (NUS)

计算机硕士 NExT++ Lab

相关课程: 数据结构、机器学习、深度学习、强化学习

## 🔗 研究方向

聚焦可信大模型系统与 Agent 架构, 研究方向覆盖多步 RAG、Agent 自进化、记忆治理、高约束场景评测与业务智能落地。具备从真实问题抽象、任务定义、评测体系设计、系统实现到业务闭环验证的完整实践经验。

## 🔧 技术能力

- 大模型与 Agent 系统: 熟悉 Agentic Workflow、Agent Harness、任务分解、多 Agent 协作、工具调用与业务动作闭环, 具备从真实业务问题抽象为 Agent 决策系统的实践经验。
- RAG 与上下文工程: 具备多步 RAG、长上下文管理、证据链路优化、上下文压缩、检索增强推理与多模态 RAG 系统经验, 能够围绕召回质量、证据保留、推理稳定性与延迟成本进行系统级优化。
- 可信评测与可验证执行: 熟悉大模型安全性、稳定性与一致性评测方法, 具备 Benchmark 构建、Failure Taxonomy、Rubric-based / Evidence-driven Scoring、多模型横评、消融实验与误差归因分析经验; 能够结合结构化输出建模、Schema 约束、规则验证与物理/安全约束, 将开放式模型输出转化为可验证、可比较、可复现的系统结果。
- 多模态与领域大模型: 具备视觉语言模型、医学影像理解、具身时序建模、视觉 RAG 与业务智能搜索经验, 关注高结构化输入输出、高安全约束与真实业务场景下的大模型能力边界。
- 科研工程与实验管理: 熟练使用 Python、PyTorch、Linux、Git、LaTeX 等工具, 具备大规模实验组织、数据处理、结果可视化、高水平论文写作与跨团队协作经验。

## 🏢 实习经历

### 🇺🇸 美国

大模型算法实习生

2026.05 – 至今

多步视觉 RAG 与业务智能

- 面向业务多步视觉 RAG 场景, 重构检索—推理—评测闭环, 搭建三路混合检索与多步推理框架, Recall@3 从 51.9% 提升至 79%+。
- 主导 85+ 组受控实验, 系统分析检索策略、推理参数、上下文积累、视觉质量与 Agent 框架对最终准确率和延迟的影响, 沉淀出可量化的 VEB 信息瓶颈理论, 揭示上下文积累对视觉注意力的系统性损耗规律。
- GPT-4.1 严判准确率从内部 Baseline 70.8% 提升至 81.5% (+10.7pp), P50 推理延迟从 164s 降至 21s; 沉淀出可迁移至新业务数据集的可扩展配置方案。
- 框架迁移到用户 query 结合多模态改写与纯文本任务, 分别实现在业务数据集上 +7pp 与 +4pp 的效果提升, 证明了框架的泛用性

### 🇨🇳 华住集团

企业 Agent 落地实习生

2025.10 – 2026.01

智能餐饮供应链 / AI 赋能基础设施

- 参与华住餐饮供应链 AI 赋能基础设施建设, 围绕智能统购、批量采购、补货决策与菜单规划等核心业务场景, 梳理业务流程、规则约束、数据输入输出与模型可介入环节。
- 设计并实现早期多 Agent 决策原型, 将采购需求分析、商品/供应商信息抽取、补货建议与菜单规划拆解为可调用、可组合的任务模块, 构建从数据接入、需求理解到策略推荐的端到端实验流程。
- 面向智能统购场景, 参与抽象门店需求、价格信号、供应商策略、商品约束与业务审核规则, 将复杂运营规则沉淀为可被模型调用、判别和迭代的结构化能力单元。
- 通过多轮业务沟通、原型验证与反馈迭代, 探索有限上下文 Agent 驱动的结构化 skill 生成与判别机制, 强调结果可解释、业务可校验与人工可复核; 相关前置工作后续被整理扩展为 ProcuraClaw 采购搜索与智能统购论文并投稿 CIKM 2026。

### 🇨🇳 海豚之声医疗科技有限公司

大模型评测算法实习生

2025.04 – 2025.09

视觉语言模型评测

- 主导医学超声场景下视觉语言模型的部署、调用与评测工作, 支持大规模医学 VLM Benchmark 实验的实施与结果整理。
- 进行 U2-BENCH 超声 benchmark 与 DOLPHIN 超声大模型项目的设计与实现, 相关成果分别面向 ICLR 2026 与 EMNLP 2026 投稿。
- 负责 Prompt 策略设计、结构化数据整理与模型输出分析, 撰写代表性实验报告与案例分析材料, 为模型能力判断和论文写作提供支撑。

### 🇨🇳 北京飞熊科技有限公司

实习生

2024.07 – 2024.09

无人机研发部门

- 参与无人机通信链路相关的安全测试与问题排查工作, 协助完成通信系统中的缺陷定位与功能验证。

## 🔬 科研与项目经历

Agent 系统、RAG 与业务智能

### 🔧 Self-Evolving Multi-Agent Systems in Open MAS: An Online MemoryAgent Paradigm

第一作者

论文撰写阶段, 预计投稿 ICLR 2027

- 提出面向 Open MAS 的 training-free 自进化范式, 在 cooperative、mixed-motive、adversarial 三种社会结构下统一验证框架泛化能力。
- 设计独立 Online MemoryAgent 架构, 将记忆管理从主 agent 推理流程中解耦: 通过 hook 机制实时维护 Episodic / Semantic / Working 三区结构化记忆文档, 由代码而非 LLM 生成更新建议, 保证主任务上下文干净性。
- 在 LoCoMo、LongMemEval、MemoryAgentBench 上验证, 外部 MemoryAgent 管理相较 In-Context 自管记忆实现稳定性提升, 接近 RL-based 方法效果, 无需额外训练数据。

### 🔍 Visual Evidence Bottleneck (VEB): A Unified Framework for Multi-Step Visual RAG

第一作者

论文撰写阶段, 预计投稿 ICLR 2027

- 发现多步视觉 RAG 中视觉注意力瓶颈现象: 随上下文积累, 命中准确率在推理第 7 步后系统性崩溃 38pp, 可量化拟合  $R^2=0.96$ 。
- 提出 VEB 信息瓶颈框架, 将优化路径分解为三个正交模式——R 减少输入噪声、A 调整记忆保留、E 扩展视觉通道, 从理论直接推导出 E1 动态像素补偿机制。
- 提出负向预测原则, 14 组实验全部命中,  $p < 10^{-4}$ ; 跨数据集验证: ViDoSeek +10.5pp、SlideVQA +5.5pp、业务数据 +15.7pp。

### 🌌 Long-Horizon Memory Governance for LLM Agents

共同第一作者

AAAI 2027 在投

- 参与提出 LHMG 框架, 将 LLM Agent 记忆建模为可治理、可审计的系统状态, 通过冲突感知 Revision Graph、Risk-Gated Memory Conditioning、Consistency-Constrained Decoding 与 Governed Forgetting 四个互补机制协同解决长时记忆漂移问题。

- Revision Graph 引入 append-only 版本化记录与不可变审计日志，冲突事实更新准确率从基线 40% 提升至 100%；Consistency-Constrained Decoding 基于 NLI 打分抑制矛盾输出，GPT-4o 上跨轮次决策一致性提升最高 13pp。
- 在 LongMemEval、多会话 Persona-QA 与安全关键决策任务上以 GPT-4o、DeepSeek-V3、LLaMA-3.3-70B 等模型系统验证，消融实验确认 Revision Graph 与 Consistency-Constrained Decoding 贡献最大。

## 🔍 ProcuraClaw: Context-Aware Procurement Search via Adaptive Hotel Profiling

共同第一作者

CIKM 2026 在投

- 基于华住供应链实习中的业务探索，参与采购、补货与菜单规划等真实场景的问题拆解、流程梳理与 Agent 原型实验，为后续上下文感知采购搜索系统提供场景定义与业务规则基础。
- 参与整理酒店采购场景中的需求表达、商品约束、供应商策略与运营反馈，将真实业务流程抽象为可建模、可评测、可迭代的采购智能化问题。
- 后续论文在此基础上进一步扩展为 ProcuraClaw 系统，围绕酒店画像、商品目录与供应链策略构建企业级采购搜索框架，并在公开基准与华住真实流量中进行验证。

## 🔗 SchemaBridge: A Unified Schema Interface and Corpus for Cross-Task Semantic Parsing

第一作者

EMNLP 2026 System Demo 在投

- 面向电信多端设备与智能业务助手中的意图识别、槽位抽取和结构化信息抽取需求，负责论文方法主线与业务场景叙事构建，将多意图、多槽位解析问题组织为统一语义解析任务。
- 围绕 USP 的 category-args 层级表示方法，梳理 NER、RE、EE、SLU 四类任务到统一 Schema 的映射逻辑，并组织 61 个数据集、275 万级多语言语料与统一评测协议的论文表达。
- 梳理生产级 Intent Engine 与实验分析部分，围绕 Parallel Match 策略、低延迟多端部署和训练-部署 Schema mismatch 问题，提炼统一语义解析系统的 Sys demo，投稿至 EMNLP System Demo Track。

具身与安全约束场景可信评测

## ✈️ PilotBench: A Benchmark for General Aviation Agents with Safety Constraints

第一作者

IJCNN 2026

- 提出并设计首个面向具身飞行场景的轨迹—姿态联合预测任务，整理并处理 708 条真实飞行数据，构建覆盖数据预处理、任务定义、模型评测与结果分析的统一端到端评测流程。
- 对 41 个开源模型及传统预测器进行系统评测，引入 PILOT-SCORE 复合指标融合回归精度、指令遵循与安全合规三个维度；主导实验执行、结果分析，撰写系统性失效案例总结，揭示精度—可控性二元对立与动态复杂性缺口。
- 持续扩展数据集与评测体系，推进面向飞行场景的专项模型研发，为后续 FLY-EVAL++ 与 FTAP 时序建模工作提供先导证据基础。

## ✈️ FLY-EVAL++: An Evidence-Driven Evaluation Protocol for Safety-Constrained Flight Prediction

第一作者

COLM 2026

- 针对高输入输出维度、强物理约束与高安全要求的具身系统评测空白，提出证据驱动的两阶段框架：第一阶段基于形式化证据原子定义对结构化输出合规性、物理可行性与 FAA 安全约束进行确定性验证；第二阶段通过评分标准聚合生成可解释的多维度判断，全程不依赖 LLM 打分，保证完全可复现性。
- 构建覆盖 34 通道传感器输入与多阶段姿态—轨迹联合输出的评测任务体系，配套 20 条 FAA 操作安全约束库，将评测从单步扩展至多步滚动时序预测，揭示 LLM 在高维物理状态空间中随时序复杂度升高的系统性失效分层规律。
- 对 66 个 LLM 过滤后选取 21 个进入全量评测，识别出安全合规为最具区分度维度，性能相近模型安全得分差距超 28 分；识别并定义 5 类跨模型系统性失效模式：协议合规失效、字段有效性失效、物理一致性失效、安全约束盲区、预测精度退化。
- 研究揭示当前基础模型在安全关键具身场景中的根本能力边界，提供可复用的评测设计范式，后续工作预计可迁移至机器人操控、自动驾驶等高约束具身领域。

## ✈️ Safety-Constrained Temporal Flight Modeling with Foundation Models

共同第一作者

进行中，预计投稿 *Nature Machine Intelligence*

- 围绕安全关键、长时序、具身飞行系统中的基础模型可信性问题，构建统一研究框架。
- 重建高保真 FTAP 时序数据集，并融合多个公开航空数据源，构建更具物理约束与长时程特征的飞行建模基准。
- 设计可信评测协议，显式区分物理可行预测与语言合理但存在安全风险的输出，提升评估对真实应用场景的解释力。
- 探索面向飞行领域基础模型的安全约束训练目标，目前正在开展模型训练、消融实验与方法验证。

领域大模型与多模态基础设施

## 👨👩 U2-BENCH: Benchmarking Large Vision-Language Models on Ultrasound Understanding

核心贡献者 作者

ICLR 2026

- 共同开发 U2-BENCH，构建面向超声影像理解任务的大模型评测基准。
- 整理并结构化 7241 张超声影像与诊断文本，覆盖分类、检测、回归、文本生成等 8 项任务，支撑多维度模型能力评估。
- 部署并评测 20 个通用及医学视觉语言模型，完成结果收集、核验与规范化整理，保证实验结果的可比性与可靠性。
- 负责性能分析与可视化展示，参与论文关键图表、对比结果与分析结论的整理。

## 👨👩 DOLPHIN: A Multimodal Large Language Model for Ultrasound Understanding

核心贡献者 共同一作外首位作者

EMNLP 2026 在投

- 参与构建 Dolphin 三阶段训练对应评测流程：后训练阶段在 2M+ 超声专科与通用推理样本上建立模型基础；指令微调阶段融合多轮对话与深度推理任务；UARPO 强化学习阶段通过超声答案奖励引导模型对齐临床诊断标准。
- 负责推理模式与标准模式的对照评测实验，以及跨 16 个身体部位的泛化能力分析；整理测量误差与检测漏报等失效案例，为消融实验与论文撰写提供实验支撑。
- Dolphin 在 U2-Bench 上以 U2-Score 0.5835 达到 SOTA；推理模式相较标准模式诊断准确率提升 2.4%、测量 RMSE 降低 10.6%、检测准确率提升 16%，并已部署至真实超声设备。

## 🧠 NeuroMark: Multi-Modal Evaluation for Neuropsychiatry with Joint Trustworthiness Metrics

共同第一作者

论文整理中，预计投稿 *Nature Communications*

- 参与项目整体规划与论文叙事逻辑构建，将神经精神科大模型评测组织为文本医学推理与脑影像视觉理解双轨任务，明确任务边界、模型范围、评测目标与可信度分析主线。
- 主导 BrainVLM 视觉评测流程建设，整合多源脑 MRI 数据集并组织 16 个 VLM 在 6 类任务上的统一推理、结果解析、准确率统计与跨任务对比分析。

## 💖 H2HTalk: Evaluating Large Language Models as Emotional Companion

核心贡献者 第二作者

NLPCC 2025 Oral Paper

- 参与构建情感伴侣评测框架，聚焦情感支持与人格一致性两大核心能力，覆盖对话场景设计、评测规则制定与自动化打分流程；在 4,800+ 多轮对话场景中对 49 个开源模型进行测试、数据处理与评估，场景涵盖日常交流、记忆调用与情绪反馈等任务。
- 采用 ROUGE、BERTScore 评估模型回复质量，并用于情境化用户角色的比较实验；分析模型在情感交互中的典型失效模式，揭示长程记忆保持与隐式需求理解是当前 LLM 情感伴侣能力的主要瓶颈。
- 引入基于依恋理论的 SAP 模块为情感交互提供安全边界与情绪调节支撑；消融实验显示去除 SAP 后违规率提升一个数量级，安全感知评分显著下降，验证心理学框架对情感伴侣安全性的关键作用。