

吴亚伦

✉ aaaronwww@outlook.com

☎ (+86) 189-4058-1177 (+65) 9812-5849

📍 新加坡国立大学，新加坡



🎓 教育背景

北京航空航天大学 (BUAA)

工学学士，网络空间安全专业

2021.09 – 2025.07

GPA: 89/100

新加坡国立大学 (NUS)

计算机硕士 NExT++ Lab

2025.08 – 2026.12 (预计)

相关课程：数据结构、机器学习、深度学习、强化学习

语言能力：雅思 6.5；GRE 322 (Verbal 152 / Quantitative 170)

🔗 研究方向

聚焦可信大模型系统与 Agent 架构，研究方向覆盖多步 RAG、Agent 自进化、记忆治理、运行时验证及高约束场景评测。具备从真实问题抽象、任务定义、评测体系设计、系统实现到业务部署与反馈验证的完整实践经验。

💻 技术能力

- **大模型与 Agent 系统**：熟悉 Agentic Workflow、Agent Harness、任务分解、多 Agent 协作与工具调用，具备将真实业务需求转化为 Agent 决策流程、结构化记忆与可验证执行机制的实践经验。
- **RAG 与上下文工程**：具备多步 RAG、长上下文管理、证据链路优化、上下文压缩与多模态检索增强推理经验，能够围绕召回质量、证据保留、推理稳定性及延迟成本开展系统优化。
- **可信评测与可验证执行**：熟悉 Benchmark 构建、失效模式归纳、证据驱动评分、多模型横评、消融实验与误差归因；能够结合结构化输出、Schema 约束、运行时校验及物理/安全规则设计可复现的评测流程。
- **多模态与领域大模型**：具备视觉语言模型、医学影像理解、具身时序建模、视觉 RAG 与业务智能搜索经验，关注高结构化输入输出、高安全约束与真实业务场景下的模型能力边界。
- **科研工程**：熟练使用 Python、PyTorch、Linux、Git、LaTeX，具备模型部署、数据处理、批量实验、可视化、科研写作与跨团队协作经验。

🏢 实习经历

🌸 美团

大模型算法实习生

2026.05 – 至今

多步视觉 RAG 与业务智能

- 面向线上知识库问答，搭建三路混合检索与多步视觉 RAG，优化证据筛选、跨步记忆与视觉输入，Recall@3 从 51.9% 提升至 79%+。
- 主导 85+ 组受控实验，系统分析检索策略、推理参数、上下文积累、视觉质量与 Agent 框架对最终效果的影响，梳理检索命中、证据利用与推理成本之间的关系，形成可迁移的配置与调优流程。
- 内部严格评测准确率从 70.8% 提升至 81.5% (+10.7pp)，P50 推理延迟从 164s 降至 21s，在提升问答准确率的同时降低线上推理开销。
- 将框架扩展至用户查询的多模态改写与纯文本问答，在业务数据集上分别提升 7pp 与 4pp，验证跨任务通用性，完成查询改写上线。

🌸 华住集团

企业 Agent 落地实习生

2025.10 – 2026.01

智能餐饮供应链 / AI 赋能基础设施

- 参与餐饮供应链 AI 基础设施建设，围绕统购、批量采购、补货与菜单规划，梳理业务流程、规则和数据输入输出，明确模型承担的任务。
- 设计并实现早期多 Agent 决策原型，将采购需求分析、商品/供应商信息抽取、补货建议与菜单规划拆解为可调用的任务模块，构建从数据接入、需求理解到策略推荐的端到端实验流程。
- 结合业务沟通、原型验证与反馈迭代，整理门店需求、价格信号、商品约束和供应商策略，探索结构化 skill 生成与判别机制；相关工作为后续 LFUSE 商品搜索研究提供场景定义与业务规则基础。

🐬 海豚之声医疗科技有限公司

大模型评测算法实习生

2025.04 – 2025.09

视觉语言模型评测

- 主导医学超声视觉语言模型的部署、调用与基准评测，完成实验执行、结果核验和统一格式整理，支持跨模型能力比较。
- 参与 U2-BENCH 基准建设与 DOLPHIN 超声大模型评测，开展推理模式对照、跨身体部位泛化分析及消融实验，支持模型迭代。
- 负责 Prompt 策略设计、结构化数据整理与模型输出分析，撰写代表性实验报告和失效案例分析，为论文关键图表与研究结论提供支撑。

🐻 北京飞熊科技有限公司

实习生

2024.07 – 2024.09

无人机研发部门

- 参与无人机通信链路相关的安全测试与问题排查工作，协助完成通信系统中的缺陷定位与功能验证。

🔬 科研与项目经历

Agent 系统、RAG 与业务智能

🔍 TAEC: Trajectory-Aware Evidence Coordination for Multi-Step Visual RAG

第一作者

ICLR 2027 在投

- 针对多步视觉 RAG 中“检索到证据却未能有效利用”的问题，提出无需训练的轨迹级证据协调框架，以未满足的回答需求作为共享状态，统一指导证据准入、历史记忆呈现与视觉细节分配，缓解跨步上下文干扰。
- 设计需求覆盖与去冗余联合筛选、自适应记忆呈现及需求感知视觉预算分配，保留有效观察、压缩已解决信息并收束失败分支。
- 在 3 个基准、4 个骨干模型的 12 组设置中，主表平均准确率达 **66.8%**，较 DAG 基线提升 **4.5pp**；同一骨干下在 ViDoSeek、SlideVQA、MMLongBench-Doc 上分别提升 **7.4/6.9/5.6pp**。

🔧 EvolveMAS: A Unified Self-Evolution Framework for Decentralized Multi-Agent Systems

第一作者

ICLR 2027 在投

- 提出面向去中心化多 Agent 系统的自进化框架，在合作、混合动机与对抗场景中，统一支持局内在线适应与跨局知识演化。
- 为每个主 Agent 配置独立 MemoryAgent，在主推理上下文外维护情景、语义与工作记忆；通过 Execute-Evaluate-Evolve 流程提炼可复用策略与伙伴画像，指导后续决策，无需更新模型参数。
- 在 5 个基准、6 组配置中取得最高归一化平均分 **77.2**，较 Self-Memory 提升 **7.7 分**；二因素消融验证记忆治理与跨局知识复用的独立贡献。

🛠️ How Much Specification Does External Supervision of an Agent Need?

通讯作者

ICLR 2027 在投

- 围绕 Agent 虚假完成与运行时验证，研究外部监督所需的可执行任务条件；在固定模型、任务与步数预算下，系统比较条件覆盖率与条件组成对任务完成率及错误放行的影响。
- 通过任务内条件替换、跨模型迁移及反馈与强制执行对照，揭示覆盖模型自身易失败的条件对监督可靠性的作用，并区分运行时掌握检查条件与向 Agent 提供条件反馈的效果。
- 在 50% 条件覆盖率下，依据另一模型的稳定失败记录优先选取检查条件，使两个模型的任务严格通过率较随机选择分别提升 **18.5/19.3pp**，同时降低未完成的任务的错误放行比例。

👤 LHMGM: Long-Horizon Memory Governance for LLM Agents

共同第一作者

AAAI 2027 在投

- 参与长时记忆治理框架研究，以版本化修订、风险门控、约束解码和治理式遗忘管理 Agent 记忆状态，缓解事实冲突与记忆漂移。
- 通过版本化记录和不可变审计日志，将冲突事实更新准确率由 40% 提升至 100%；结合 NLI 打分抑制矛盾输出，跨轮次决策一致性最高提升 13pp，并在长时记忆与多会话任务中开展验证。

🔍 LFUSE: Learned Evidence Fusion for Noisy Spoken and Image-Grounded Product Search

共同第一作者

ICASSP 2027 在投

- 面向含噪语音与图像条件下的商品搜索，结合华住采购、补货与菜单规划场景，参与问题拆解、流程梳理及 Agent 原型实验。
- 整理需求表达、商品约束、供应商策略与运营反馈，将业务规则转化为可建模、可评测的搜索任务，支持 LFUSE 的任务定义与评测设计。

🏗️ SchemaBridge: A Unified Schema Interface and Corpus for Cross-Task Semantic Parsing

第一作者

NAACL 2027 拟投

- 面向多端设备与业务助手的意图识别、槽位抽取和信息抽取需求，负责统一语义解析的方法主线与论文组织，梳理 NER、RE、EE、SLU 四类任务到 category-args 层级 Schema 的映射。
- 整理 61 个数据集、275 万级多语言语料与统一评测协议，分析生产级 Intent Engine 的 Parallel Match、部署延迟及训练-部署 Schema 差异。

具身与安全约束场景可信评测

✈️ FLY-EVAL++: An Evidence-Driven Evaluation Protocol for Safety-Constrained Flight Prediction

第一作者

COLM 2026

- 面向高维、强物理与安全约束的飞行预测，提出证据驱动的两阶段评测协议：以形式化证据原子确定性验证结构化输出、物理可行性与 FAA 安全约束，再按评分标准聚合为可解释的多维指标，全程无需 LLM 打分。
- 构建覆盖 34 通道传感器输入、多阶段姿态-轨迹联合输出与 20 条 FAA 操作约束的任务体系，将评测从单步扩展至多步滚动预测，分析时序复杂度增加时的精度退化及安全风险。
- 对 66 个 LLM 筛选后选取 21 个开展全量评测，发现性能相近模型的安全得分差距超过 28 分，归纳协议合规、字段有效性、物理一致性、安全约束盲区与预测精度退化五类系统性失效。
- 揭示仅以预测精度衡量模型不足以反映高约束场景中的实际可靠性，形成从真实领域规则构建评测指标、验证安全边界与分析失效的可复用流程，为其他具身应用的可信评测提供参考。

✈️ PilotBench: A Benchmark for General Aviation Agents with Safety Constraints

第一作者

IJCNN 2026

- 设计飞行场景的轨迹-姿态联合预测任务，处理 708 条真实飞行数据，建立数据预处理、任务定义、模型评测与结果分析流程。
- 系统评测 41 个模型及传统预测器，设计 PILOT-SCORE 融合回归精度、指令遵循与安全合规，主导实验、结果核验及模型比较。
- 分析预测精度与可控性的权衡，归纳动态复杂场景的系统性失效，为 FLY-EVAL++ 评测协议与 FTAP 时序建模提供任务基础和先导证据。

✈️ Safety-Constrained Temporal Flight Modeling with Foundation Models

共同第一作者

Nature Machine Intelligence 拟投

- 围绕安全关键、长时序飞行建模，参与高保真 FTAP 时序数据重建与多源公开航空数据整合，构建含物理约束的长时程预测基准。
- 设计区分物理可行预测与语言合理但存在安全风险输出的可信评测协议，探索安全约束训练目标，推进模型训练、消融实验与方法验证。

领域大模型与多模态基础设施

👤 U2-BENCH: Benchmarking Large Vision-Language Models on Ultrasound Understanding

核心贡献者、作者

ICLR 2026

- 参与构建超声影像理解评测基准，整理并结构化 7,241 张超声影像与诊断文本，覆盖分类、检测、回归、文本生成等 8 类任务。
- 部署评测 20 个通用及医学视觉语言模型，完成推理调用、结果核验与统一格式整理，确保跨模型结果可比、实验流程可复现。
- 负责性能分析与可视化，整理关键图表、对比实验和分析结论，结合失效案例解释模型在超声理解任务中的能力差异。

♥️ H2HTalk: Evaluating Large Language Models as Emotional Companion

核心贡献者、第二作者

NLPCC 2025 Oral Paper

- 参与构建聚焦情感支持与人格一致性的情感伴侣评测框架，覆盖场景设计、评测规则与自动化打分流程；在 4,800+ 多轮对话场景中测试 49 个模型，完成数据处理与评估。
- 采用 ROUGE、BERTScore 评估回复质量并开展情境化用户角色比较实验，分析记忆调用、情绪反馈与隐式需求理解中的典型失效，识别长程记忆保持和需求理解的能力瓶颈。
- 结合基于依恋理论的 SAP 模块分析情感交互的安全边界与情绪调节能力；消融实验显示，去除 SAP 后违规率上升一个数量级，验证心理学框架对情感伴侣安全性的作用。

👤 DOLPHIN: A Multimodal Large Language Model for Ultrasound Understanding

核心贡献者、共同一作外首位作者

CVPR 2027 拟投

- 参与覆盖后训练、指令微调与 UARPO 强化学习三个阶段的评测流程；负责推理模式与标准模式对照及跨 16 个身体部位的泛化分析，整理测量误差、检测漏报等失效案例。
- 模型在 U2-BENCH 上取得 U2-Score 0.5835；推理模式相较标准模式诊断准确率提升 2.4%、测量 RMSE 降低 10.6%、检测准确率提升 16%。

👤 NeuroMark: Multi-Modal Evaluation for Neuropsychiatry with Joint Trustworthiness Metrics

共同第一作者

Nature Communications 拟投

- 参与神经精神科大模型评测与论文规划，构建文本医学推理和脑影像视觉理解双轨任务，明确任务边界、模型范围与可信度分析。
- 主导 BrainVLM 视觉评测流程，整合多源脑 MRI 数据，组织 16 个 VLM 在 6 类任务上的统一推理、结果解析、准确率统计与跨任务比较。